



Facultad de Ingenierías

Análítica de Datos I

Ingeniería de Datos e IA

Prof's. Carlos Ferro - Cristian E García

Proyecto Final

GeoVision-CLIP Cali — Estimación de Contaminación Atmosférica en Puntos No Muestreados mediante Deep Learning + Estadística Geoespacial Avanzada

Tercer Corte · Unidad III · Grupos de 3 estudiantes · Duración: 4 semanas

Condiciones:

- Subir el proyecto en formato PDF en la plataforma UAO-Virtual. Se debe entregar un informe y los archivos adicionales (códigos, notebooks, checkpoints, manifests) se deben entregar como anexo. El informe no debe contener más de 25 páginas, incluidas las imágenes y tablas.
- Es necesario incluir el código de Python (PyTorch + GeoPandas + PyKriging + PySAL). Mostrar los resultados mediante tablas, gráficos o indicadores que les permitan responder a los planteamientos. Los KPIs deben reportarse con evidencia computacional verificable (hashes MD5 de checkpoints, logs de entrenamiento, capturas del sistema desplegado).
- Deben interpretar los resultados obtenidos en cada situación de acuerdo al contexto agroclimático y de salud ambiental de Santiago de Cali y su área metropolitana.
- Realizar la actividad en los grupos definidos anteriormente (3 integrantes). Cada integrante debe poder defender técnicamente cualquier sección del proyecto.
- Subir la tarea en un archivo .ZIP que contenga el informe en PDF, los notebooks Jupyter ejecutados con outputs visibles, el manifest del dataset (con hashes MD5), el Dockerfile y las URLs públicas del sistema desplegado y del repositorio Git.
- Está PROHIBIDO usar Streamlit, Gradio o cualquier framework de prototipado rápido como frontend principal. Se exige aplicación web profesional (React / Vue / Next.js).

Resumen Ejecutivo

Santiago de Cali es la tercera ciudad de Colombia y enfrenta una problemática creciente de calidad del aire asociada al transporte vehicular, la industria del Valle del Cauca, las quemadas de caña de azúcar y los aportes regionales del Pacífico biogeográfico. La red de monitoreo terrestre del DAGMA (9 estaciones operativas) y los reportes del IDEAM al SISAIRE proporcionan series temporales puntuales de NO_2 , SO_2 y O_3 troposférico, pero su densidad espacial es insuficiente para representar la heterogeneidad de la exposición poblacional a escala intraurbana. El presente proyecto integrador propone resolver este problema mediante una arquitectura híbrida que combina: (i) un sistema de aprendizaje multimodal contrastivo basado en CLIP + Sparse Autoencoders sobre imágenes Sentinel-2 y Sentinel-5P, (ii) un módulo espacio-temporal de pronóstico mediante ConvLSTM, y (iii) Kriging Espacio-Temporal (ST-Kriging) que cierra el ciclo geoestadístico estimando concentraciones de los tres contaminantes en puntos no muestreados, con cuantificación explícita de la incertidumbre.

El proyecto se evalúa sobre tres situaciones secuenciales y acumulativas. La Situación 1 obliga a los estudiantes a construir un panel analítico de al menos 50 GB en formato optimizado (Zarr o Parquet) sobre infraestructura cloud, ejercitando capacidades reales de ingeniería de datos masivos. La Situación 2 implementa el núcleo de Deep Learning (GeoVision-CLIP + SAE) y valida psicométricamente las representaciones latentes mediante AFE/AFC. La Situación 3 articula el aprendizaje profundo con la estadística geoespacial avanzada para producir mapas continuos de contaminación validados contra las estaciones del DAGMA mediante leave-one-out cross-validation, y caracteriza perfiles tipológicos de zonas críticas dentro de la huella urbana de Cali.

Contexto y Fundamentación

Problema científico y de salud pública

La Resolución 2254 de 2017 del Ministerio de Ambiente establece niveles máximos permisibles para NO_2 , SO_2 y O_3 , pero su verificación a escala urbana depende de redes de monitoreo costosas y dispersas. El DAGMA opera nueve estaciones distribuidas heterogéneamente sobre los 564 km² del municipio, lo que deja amplias zonas de Cali sin cobertura directa (laderas, sur del municipio, zona industrial Yumbo–Acopi). La pregunta operativa es: ¿podemos estimar las concentraciones de NO_2 , SO_2 y O_3 en cualquier punto (lat, lon) de la ciudad, con incertidumbre cuantificada, usando exclusivamente datos satelitales gratuitos y unas pocas estaciones de validación?

Por qué Deep Learning + Estadística Geoespacial

Sentinel-5P TROPOMI provee columnas troposféricas de NO_2 , SO_2 y O_3 con resolución nativa de 3.5×5.5 km y revisita diaria, pero esta resolución es demasiado gruesa para diferenciar la exposición de un barrio respecto a otro. Sentinel-2 MSI, por el contrario, ofrece 10 m de resolución pero no observa los gases directamente: solo proporciona covariables proxy (NDVI, BSI, índices urbanos, sombra de edificaciones). El reto es realizar downscaling estadístico fusionando ambas fuentes. La hipótesis del proyecto es que un modelo CLIP fino-ajustado al dominio satelital aprende un espacio latente donde los embeddings codifican simultáneamente firma espectral y semántica geográfica; sobre ese espacio, un ConvLSTM captura la dinámica temporal y un Kriging Espacio-Temporal lo proyecta a una superficie continua interpretable, con varianza de predicción que sirve como mapa de confianza. El cierre del ciclo es estadístico: el variograma experimental de los residuos del modelo profundo debe ser nugget puro para considerarse adecuado, y el Índice de Moran sobre las predicciones cuantifica si el modelo aprendió coherencia geográfica o predice ruido.

Situación 1 (1.0 Pts)

Construcción del Panel Espacio-Temporal y Arquitectura Cloud

Se requiere construir un panel analítico longitudinal de mínimo 50 GB que integre 5 años de imágenes satelitales sobre el área metropolitana de Santiago de Cali (latitud 3.30°N a 3.55°N ; longitud -76.60°W a -76.40°W), incluyendo el corredor industrial Yumbo–Acopi y la zona de cultivos de caña del norte del Valle. El panel debe permitir el estudio conjunto de: (a) columnas troposféricas de NO_2 , SO_2 y O_3 provenientes de Sentinel-5P TROPOMI, (b) covariables ópticas de alta resolución provenientes de Sentinel-2 MSI, (c) covariables meteorológicas de reanálisis ERA5-Land, y (d) ground truth puntual de las estaciones del DAGMA y los reportes SISAIRES.

Fuentes de datos obligatorias

Fuente	Variable	Resolución espacial	Periodicidad	Acceso
Sentinel-5P L2 OFFL	NO_2 troposférico	3.5×5.5 km	Diaria (1–2 órbitas)	Copernicus DataSpace · GEE
Sentinel-5P L2 OFFL	SO_2 vertical column	3.5×5.5 km	Diaria	Copernicus DataSpace · GEE
Sentinel-5P L2 OFFL	O_3 total column	3.5×5.5 km	Diaria	Copernicus DataSpace · GEE
Sentinel-2 L2A	13 bandas (B2–B12)	10/20/60 m	5 días	Copernicus · GEE · AWS Open Data

Fuente	Variable	Resolución espacial	Periodicidad	Acceso
MODIS MCD19A2	AOD (proxy PM)	1 km	Diaria	NASA Earthdata · GEE
ERA5-Land	T2m, viento, BLH, RH	9 km	Horaria	Copernicus CDS
DAGMA / SISAIRE	NO ₂ , SO ₂ , O ₃ in-situ	9 estaciones	Horaria	sisaire.ideam.gov.co

Verificación del peso del dataset

El equipo docente verificó analíticamente la viabilidad del umbral. Considerando 5 años (1825 días), 2 órbitas/día sobre Cali y 3 contaminantes, el volumen del componente Sentinel-5P L2 sin recortar asciende a ≈ 10.2 TB. Aplicando recorte HARP a la huella metropolitana de Cali, se reduce a ≈ 254 GB para Sentinel-5P solamente. Sumando 4 tiles de Sentinel-2 con filtro de nubosidad $< 60\%$ (≈ 164 adquisiciones útiles/tile), el componente óptico añade ≈ 513 GB. ERA5-Land aporta ≈ 143 GB y MODIS MAIAC ≈ 89 GB. Cualquier escenario realista de implementación supera holgadamente el umbral de 50 GB, lo que obliga al uso de almacenamiento de objetos y procesamiento distribuido.

Escenario de descarga	Recortes aplicados	Peso estimado
Mínimo (Cali + S2 parcial)	BBox Cali, S2 50%	≈ 626 GB
Intermedio (Colombia recortado)	BBox Colombia + todas las fuentes	≈ 2.4 TB
Completo (granules sin recorte)	Sin recorte espacial	≈ 10.9 TB
Umbral mínimo del proyecto	—	≥ 50 GB

Tareas obligatorias

1. Configurar credenciales de Google Earth Engine y Copernicus DataSpace Ecosystem (CDSE). Autenticar la API de Earthdata para acceder a MAIAC.
2. Implementar pipeline de descarga distribuido en Dask o Spark. Las descargas no pueden hacerse de forma secuencial single-thread: deben paralelizar por banda, fecha y tile.
3. Aplicar recorte HARP sobre los granules L2 de Sentinel-5P para reducir a la huella metropolitana de Cali (use harpconvert con bin_spatial sobre BBox $-76.60, 3.30, -76.40, 3.55$).
4. Convertir las series temporales a formato Zarr (recomendado para arrays N-dimensionales con chunking espacio-temporal) o Parquet particionado por (año, mes, contaminante).
5. Persistir el panel en almacenamiento de objetos: Google Cloud Storage, AWS S3 o Azure Blob (cualquier free tier con créditos académicos es suficiente).

6. Construir un manifest JSON con: ruta de cada archivo, hash MD5, dimensiones, fecha de adquisición, fuente y bounding box. Este manifest debe estar versionado en Git.
7. Generar un reporte EDA con: distribución temporal de adquisiciones por contaminante, mapa de cobertura espacial efectiva, porcentaje de píxeles válidos por escena, y serie temporal media de cada contaminante para las 9 estaciones DAGMA.

Script base de descarga (referencia)

```
import ee, dask, geemap
from dask.distributed import Client

ee.Initialize(project='geovision-cali')
client = Client(n_workers=4, threads_per_worker=2, memory_limit='4GB')

cali = ee.Geometry.Rectangle([-76.60, 3.30, -76.40, 3.55])

# 5 años de NO2, SO2, O3 (Sentinel-5P)
for poll, col in [('NO2','COPERNICUS/S5P/OFFL/L3_NO2'),
                  ('SO2','COPERNICUS/S5P/OFFL/L3_SO2'),
                  ('O3','COPERNICUS/S5P/OFFL/L3_O3')]:
    ic = (ee.ImageCollection(col)
          .filterBounds(cali)
          .filterDate('2020-01-01','2024-12-31'))
    # exportar a GCS particionado por mes (paraleliza con Dask)
    futures = client.map(export_monthly_chunk, ic.toList(ic.size()), pollutant=poll)

# Verificar peso ≥ 50 GB antes de continuar
assert manifest_total_size_gb() >= 50, 'Dataset insuficiente'
```

Entregables Situación 1

- Diagrama de arquitectura cloud (almacenamiento + cómputo + orquestación).
- Manifest JSON con ≥ 50 GB de datos verificados y hashes MD5.
- Notebook EDA con mínimo 8 visualizaciones del panel.
- Reporte de costos cloud (descarga + almacenamiento) y discusión de cuellos de botella.

Situación 2 (1.5 Pts)

GeoVision-CLIP — Aprendizaje Multimodal y Reducción de Dimensionalidad

Una vez consolidado el panel, los estudiantes deben construir un modelo multimodal que aprenda representaciones conjuntas imagen-texto sobre tiles satelitales de Cali. El núcleo arquitectónico es un encoder visual ViT-B/32 inicializado con pesos de RemoteCLIP (variante de CLIP especializada en

teledetección), un encoder textual multilingüe (XLM-RoBERTa o paraphrase-multilingual-MiniLM), y dos Sparse Autoencoders simétricos insertados entre los encoders y sus projection heads. La función objetivo combina pérdida contrastiva InfoNCE con la pérdida de reconstrucción y regularización L1 de los SAE.

Especificación del modelo

Loss total (entrenamiento end-to-end):

$$L_{\text{total}} = L_{\text{InfoNCE}} + \alpha \cdot (L_{\text{sae_img}} + L_{\text{sae_txt}})$$

$$L_{\text{InfoNCE}} = -(1/N) \cdot \sum_i \log[\exp(\text{sim}(e_i, f_i)/\tau) / \sum_j \exp(\text{sim}(e_i, f_j)/\tau)]$$

$$L_{\text{sae}} = \|x - \hat{x}\|^2 + \lambda \cdot \|z\|_1$$

donde:

τ = temperatura learnable (init 0.07)

$\alpha = 0.1$ (peso regularización SAE)

$\lambda = 1e-3$ (peso sparsity)

$d = 512$ (dimensión embedding SAE)

$e_{\text{img}}, e_{\text{txt}} \in \mathbb{R}^{256}$ (espacio contrastivo)

Construcción del dataset de pares imagen–texto

- Mínimo 1000 pares (tile Sentinel-2 64×64 px, descripción en español) distribuidos en al menos 5 clases: contaminación_alta_NO₂, contaminación_alta_SO₂, ozono_anómalo, vegetación_densa, suelo_urbano.
- Etiquetado semi-supervisado: usar las concentraciones de Sentinel-5P sobre el centroide del tile como pseudo-label, agrupado por percentiles (p25, p50, p75, p90, p99 de la distribución sobre Cali en los 5 años).
- Split estratificado 70/15/15 con semilla fija (SEED=42).
- Series temporales: ≥ 30 secuencias de 8 fechas consecutivas para alimentar el módulo de forecasting de la Situación 3.

Validación psicométrica de los embeddings (AFE + AFC)

Sobre la matriz de embeddings de la rama visual ($n \times 512$), aplicar Análisis Factorial Exploratorio con extracción por Componentes Principales y rotación Varimax. Determinar el número de factores m a retener vía Scree Plot y varianza acumulada (criterio: m que explique $\geq 80\%$). Posteriormente, especificar un modelo de medición confirmatorio con cuatro constructos latentes hipotetizados — Carga Antropogénica, Estrés Vegetal, Densidad Urbana, Volatilidad Atmosférica — y evaluar bondad de ajuste con RMSEA, CFI y SRMR. Concluir sobre la validez de constructo.

KPIs de la Situación 2

KPI	Umbral mínimo	Excelente	Cómo medirlo
Recall@1 imagen→texto	≥ 0.45	≥ 0.65	clip_metrics.recall_at_k(1)
Recall@5 imagen→texto	≥ 0.70	≥ 0.85	clip_metrics.recall_at_k(5)
Sparsity ratio SAE visual	≥ 0.70	≥ 0.85	mean($z < 0.01$)
Loss reconstrucción SAE	≤ 0.05	≤ 0.02	MSE val
Varianza explicada AFE (m factores)	$\geq 80\%$	$\geq 90\%$	scree plot + acumulada
RMSEA (modelo AFC)	< 0.08	< 0.05	lavaan / semopy
CFI (modelo AFC)	> 0.90	> 0.95	lavaan / semopy

Entregables Situación 2

- Checkpoint del modelo entrenado (.pt) con MD5 verificable y reproducible entre los integrantes del grupo.
- Curvas de entrenamiento: loss total, loss InfoNCE, loss SAE, sparsity ratio por epoch.
- Reporte AFE+AFC con matriz de cargas rotada, scree plot e índices de bondad de ajuste.
- Análisis de neuronas activas del SAE para cada clase (interpretabilidad mecánica).

Situación 3 (2.5 Pts)

Predicción Geoestadística Espacio-Temporal de Contaminantes en Puntos No Muestreados

Esta situación es el corazón del proyecto: articular el modelo profundo entrenado en la Situación 2 con técnicas avanzadas de estadística geoespacial para producir, dado cualquier punto (lat, lon) en la huella metropolitana de Cali y un horizonte temporal $\{T+1, T+3, T+7 \text{ días}\}$, una estimación puntual de la concentración esperada de NO_2 , SO_2 y O_3 , junto con su varianza de predicción Kriging. El producto final son seis mapas de gradiente (3 contaminantes $\times$ 3 horizontes) renderizados como overlays interactivos en el frontend, validados externamente contra las series horarias del DAGMA mediante leave-one-out cross-validation espacial.

Pipeline integral

INPUT: (lat, lon) $\in$ Cali, radio $R \in [1, 15]$ km, contaminante $\in \{\text{NO}_2, \text{SO}_2, \text{O}_3\}$

PASO 1 — Generar grilla $N \times N$ de puntos en círculo de radio R (resolución 0.005°)

PASO 2 — Para cada punto, recuperar tile S2 + serie S5P histórica (últimas 8 fechas)

PASO 3 — Pasar tiles por GeoVision-CLIP+SAE $\rightarrow$ embeddings $\in \mathbb{R}^{(N \times N \times 8 \times 256)}$

PASO 4 — ConvLSTM espacio-temporal $\rightarrow$ predicción (3 horizontes $\times$ $N \times N$) por contaminante

PASO 5 — Ajustar variograma experimental sobre residuos del DL $\rightarrow$ modelo teórico

PASO 6 — ST-Kriging sobre las predicciones del DL $\rightarrow$ superficie continua + $\text{var}(\sigma^2)$

PASO 7 — Validación externa: LOO-CV contra estaciones DAGMA $\rightarrow$ RMSE, MAE, R^2

PASO 8 — Análisis de Moran (global y LISA) sobre la superficie predicha

OUTPUT: 9 mapas de gradiente (3 contaminantes $\times$ 3 horizontes) + mapas de incertidumbre

Componente A — ConvLSTM (Deep Learning)

Una sola red ConvLSTM bidireccional (hidden=128, kernel=3, 2 capas) procesa secuencias temporales de embeddings reorganizados en grilla espacial. La salida es un tensor (B, 3, 3, H, W) correspondiente a [horizonte] $\times$ [contaminante] $\times$ [grilla]. La capa de salida es una conv 1 $\times$ 1 que mapea los canales latentes a las 9 predicciones simultáneas. Entrenar con AdamW (lr=1e-4), early stopping sobre RMSE espacial en val, batch_size=16 secuencias.

Componente B — Kriging Espacio-Temporal (Estadística)

Sobre las predicciones del ConvLSTM en la grilla discreta, ajustar un variograma experimental separable en espacio y tiempo. Calcular nugget, sill y range para los componentes espacial y temporal. Validar el ajuste con la función objetivo de mínimos cuadrados ponderados. Posteriormente, ejecutar Kriging Ordinario 3D (PyKrige.OrdinaryKriging3D) que interpola simultáneamente en (lat, lon, t) y produce no solo el valor estimado sino también la varianza de predicción $\sigma^2(s,t)$, que se usa para construir el mapa de incertidumbre con opacidad inversamente proporcional a σ .

```
from pykrige.ok3d import OrdinaryKriging3D
import numpy as np

def st_kriging(lats, lons, times, values, q_lats, q_lons, q_t,
               variogram='exponential'):
    # Normalización (evita anisotropía espuria)
    lat_n = (lats - lats.mean()) / lats.std()
    lon_n = (lons - lons.mean()) / lons.std()
    t_n = (times - times.mean()) / (times.std() + 1e-8)

    ok = OrdinaryKriging3D(lat_n, lon_n, t_n, values,
                           variogram_model=variogram,
                           verbose=False)

    z, var = ok.execute('points',
                        (q_lats - lats.mean()) / lats.std(),
                        (q_lons - lons.mean()) / lons.std(),
                        (q_t - times.mean()) / (times.std() + 1e-8))
    return z, var # valor predicho + varianza Kriging
```


Componente C — Validación geoestadística rigurosa

- Leave-One-Out CV espacial sobre las 9 estaciones DAGMA: para cada estación e_i , entrenar con las 8 restantes y predecir e_i . Reportar RMSE, MAE y R^2 agregados por contaminante.
- Variograma de residuos: el variograma de los residuos (observado — predicho) sobre las estaciones de validación debe ser nugget puro (sin estructura espacial remanente). Esto certifica que el modelo capturó la autocorrelación.
- Índice de Moran Global I sobre la superficie predicha, con prueba de hipótesis (permutation test, $n=999$). Se espera $I > 0.30$ con $p < 0.05$.
- Análisis LISA (Local Indicators of Spatial Association) para identificar clusters de alta y baja contaminación con significancia local.
- Comparación de semivariogramas: el semivariograma de la serie observada debe ser estadísticamente equivalente al de la predicción (validación de coherencia espacial del modelo).

KPIs de la Situación 3

KPI	Mínimo	Excelente	Verificación
RMSE LOO-CV NO ₂ (T+1)	$\leq 8 \mu\text{g}/\text{m}^3$	$\leq 4 \mu\text{g}/\text{m}^3$	vs. DAGMA
RMSE LOO-CV SO ₂ (T+1)	$\leq 6 \mu\text{g}/\text{m}^3$	$\leq 3 \mu\text{g}/\text{m}^3$	vs. DAGMA
RMSE LOO-CV O ₃ (T+1)	$\leq 12 \mu\text{g}/\text{m}^3$	$\leq 6 \mu\text{g}/\text{m}^3$	vs. DAGMA
R^2 LOO-CV (promedio 3 contaminantes)	≥ 0.55	≥ 0.75	scikit-learn
Índice de Moran I (predicciones)	> 0.30 ($p < 0.05$)	> 0.50	esda.Moran
Variograma residuos (nugget puro)	Sin estructura	Sin estructura	PyKrig
Cobertura cinturón 95% (σ Kriging)	$\geq 92\%$	$\geq 95\%$	Empírico LOO
Degradación T+1 $\rightarrow$ T+7 (RMSE)	$< 60\%$ aumento	$< 30\%$	Ratio RMSE
Latencia inferencia end-to-end	< 8 s	< 3 s	time.perf_counter

Entregables Situación 3

- Notebook de entrenamiento del ConvLSTM con curvas y métricas reproducibles.
- Reporte geoestadístico: variogramas (experimental + teórico ajustado), Moran I y LISA con mapas de significancia.
- Tabla de validación LOO-CV por estación DAGMA y por contaminante.

- Sistema desplegado: dado un (lat, lon) y un horizonte, devuelve los 9 mapas de gradiente con sus respectivos mapas de incertidumbre.
- Análisis de perfiles tipológicos (clustering K-Means sobre las superficies predichas) para identificar zonas crónicas de alta contaminación en Cali.

Frontend, Despliegue e Informe Final

Especificación del frontend

El frontend debe ser una aplicación web profesional desarrollada en React + Vite, Vue 3 o Next.js. Está prohibido usar Streamlit o Gradio. La interfaz incluye un mapa interactivo Leaflet centrado en Cali con las 9 estaciones DAGMA georreferenciadas. El usuario puede: (i) hacer click en cualquier punto del mapa para consultar predicciones, (ii) seleccionar contaminante y horizonte temporal mediante controles, (iii) visualizar los 9 mapas de gradiente (3×3) con slider temporal animado entre T+1, T+3, T+7, (iv) ver la incertidumbre como capa de opacidad superpuesta, (v) inspeccionar tooltips con valor predicho $\pm \sigma$, (vi) descargar la predicción como GeoTIFF o CSV.

Stack tecnológico recomendado

Capa	Tecnología	Notas
Almacenamiento	Zarr / Parquet en GCS o S3	Particionado por (año, mes, contaminante)
ETL distribuido	Dask / Spark	obligatorio por volumen
Modelo CLIP+SAE	PyTorch + RemoteCLIP	frozen visual encoder
ConvLSTM	PyTorch nn.Module custom	implementación propia
Geoestadística	PyKriges + PySAL (esda)	OK3D + Moran
Backend API	FastAPI + Uvicorn	endpoints /predict, /validate
Frontend	React + Vite + Leaflet	no Streamlit/Gradio
Contenedor	Docker + docker-compose	imagen multi-stage
Despliegue	HuggingFace Spaces / Render	free tier suficiente
Trazabilidad	Weights & Biases	logging de runs

Estructura del informe técnico (15–25 páginas)

Sección	Contenido	Pág.
1. Resumen ejecutivo	Problema, solución, KPIs alcanzados, URL del sistema	1
2. Construcción del panel	Arquitectura cloud, manifest, EDA	3-4

Sección	Contenido	Pág.
3. Modelo GeoVision-CLIP	Arquitectura, entrenamiento, validación AFE/AFC	3-4
4. Pipeline DL + Geoestadística	ConvLSTM + ST-Kriging integrados	3-4
5. Resultados y validación	KPIs, LOO-CV, Moran/LISA, mapas	4-5
6. Análisis de ablación	Con/sin SAE, DL solo vs DL+Kriging	2
7. Despliegue	Diagrama, latencia, URL pública	1-2
8. Discusión y trabajo futuro	Limitaciones, mejoras, replicabilidad	1-2
Apéndice A	Hashes MD5, manifest, semillas	—
Apéndice B	Código clave comentado	—

Rúbrica de Calificación

Componente	Peso	Criterios
Construcción del panel (Sit. 1)	20%	≥ 50 GB verificado, manifest con MD5, EDA completo, ETL distribuido
Modelo CLIP + SAE (Sit. 2)	20%	KPIs de retrieval/sparsity alcanzados, AFE/AFC reportado
DL + Geoestadística (Sit. 3)	30%	ConvLSTM + ST-Kriging integrados, validación LOO-CV con DAGMA
Frontend y despliegue	10%	URL pública, mapas interactivos, latencia < 8 s
Informe técnico	10%	Estructura completa, rigor, KPIs con evidencia computacional
Pitch y defensa	10%	Demo en vivo, dominio de cualquier sección por cualquier integrante

Penalizaciones

- Dataset < 50 GB verificado: -40% del componente Situación 1.
- Usar Streamlit/Gradio como frontend principal: -30% del componente despliegue.
- Reportar KPIs sin evidencia computacional: -50% del componente afectado.
- MD5 del checkpoint no coincide entre integrantes: -20% del componente modelo.
- Validación LOO-CV no realizada o filtrada: -60% del componente Situación 3.
- Pasar las concentraciones de Sentinel-5P como input directo del modelo (data leakage): -25% del proyecto.

Bonificaciones

- Modo oscuro implementado en frontend: +2 puntos.
- Tercer modalidad de input (audio Whisper): +3 puntos.
- Análisis de equidad espacial (rendimiento del modelo por estrato socioeconómico de Cali): +4 puntos.
- Comparación con OMI/AURA o GOME-2 como segunda fuente independiente de validación: +3 puntos.

Recursos y Referencias

Repositorios de datos

- Copernicus Data Space Ecosystem: <https://dataspace.copernicus.eu>
- Google Earth Engine — colecciones Sentinel-5P: COPERNICUS/S5P/OFFL/L3_NO2 (también L3_SO2, L3_O3)
- Sentinel-2 L2A en AWS Open Data: <s3://sentinel-cogs/sentinel-s2-l2a-cogs/>
- MODIS MAIAC AOD: NASA Earthdata Search → MCD19A2
- ERA5-Land: Copernicus Climate Data Store (CDS API)
- SISAIRE — IDEAM: <http://sisaire.ideam.gov.co/ideam-sisaire-web/>
- DAGMA Cali — Sistema de Vigilancia: <https://www.cali.gov.co/dagma/>

Referencias técnicas clave

- Veefkind, J.P. et al. (2012). TROPOMI on the ESA Sentinel-5 Precursor. Remote Sensing of Environment, 120, 70–83.
- van Geffen, J. et al. (2022). Sentinel-5P TROPOMI NO₂ retrieval. AMT.
- Theys, N. et al. (2017). Sulfur dioxide retrievals from TROPOMI onboard Sentinel-5 Precursor. AMT.
- Liu et al. (2024). RemoteCLIP: A Vision Language Foundation Model for Remote Sensing. IEEE TGRS.
- Cressie, N. & Wikle, C. (2011). Statistics for Spatio-Temporal Data. Wiley.
- Anselin, L. (1995). Local Indicators of Spatial Association — LISA. Geographical Analysis 27(2).
- Templeton, T. et al. (2023). Sparse Autoencoders for Mechanistic Interpretability. Anthropic Technical Report.



*Universidad Autónoma de Occidente · Facultad de Ingenierías
Programa de Ingeniería de Datos e IA · Cali, Colombia · 2026*